

AEC curve 기반 low SMI 예측 연구 정리

1. 연구 목적

이 연구의 핵심 질문은 다음과 같다.

CT 영상 자체를 segmentation 하지 않고, 촬영 과정에서 생성되는 AEC curve 만으로 low SMI risk 를 예측할 수 있는가?

즉, L3 muscle segmentation 결과는 **정답 label** 을 만들기 위해 사용하지만, 실제 모델 input 에는 L3 위치나 CT image 정보가 들어가면 안 된다.

따라서 모델 구조는 다음과 같다.

Input: AEC curve $\pm$ age/sex/BMI

Outcome: low SMI 또는 low TAMA

Validation: 강남 데이터로 학습, 신촌 데이터로 외부검증

2. 현재 handcrafted feature 결과의 의미

현재 PPT 결과를 보면, handcrafted AEC feature 는 TAMA 와 관련이 있다. BMI 를 넣지 않은 age/sex 모델에 AEC feature 를 추가하면 성능이 꽤 좋아진다. 하지만 BMI 를 넣으면 AEC 의 추가 효과는 거의 사라진다. 즉 현재 결과는 AEC 가 체격/body size/attenuation proxy 로 작동하지만, BMI 를 넘어서는 독립 정보는 아직 약하다는 쪽에 가깝다.

정리하면:

질문	현재 판단
AEC feature 가 TAMA 와 관련 있는가?	있음
BMI 없이 age/sex 만 있을 때 AEC 가 도움 되는가?	도움 됨
BMI 까지 넣은 뒤에도 AEC 가 많이 도움 되는가?	거의 아님
handcrafted feature 를 더 파면 반전 가능성이 큰가?	낮음
1D CNN 을 해볼 이유가 있는가?	있음

따라서 handcrafted feature 분석은 거의 충분히 했다.

이제 핵심은 raw AEC curve 자체를 1D CNN 으로 넣었을 때, handcrafted feature 가 놓친 morphology 정보가 있는지 보는 것이다.

3. Age/Sex/BMI 와 feature selection 원칙

Age, sex, BMI 는 selection 대상이 아니다.
항상 고정해서 넣어야 하는 clinical baseline 이다.

AEC feature selection 은 다음 순서가 좋다.

Step 1. AEC feature 끼리 중복 제거

mean, p25, AUC 처럼 거의 같은 정보를 담는 feature 는 하나만 남긴다.

Step 2. Age/Sex/BMI 를 고정한 상태에서 AEC feature 선택

즉, 질문은 이것이다.

Age/Sex/BMI 를 이미 넣었을 때도 추가로 도움 되는 AEC feature 가 무엇인가?

Step 3. VIF 확인

BMI 와 VIF 가 높다는 이유만으로 AEC feature 를 바로 제거하면 안 된다.

VIF 는 “이 feature 가 BMI 와 겹칠 가능성이 있다”는 경고 신호다.
최종 판단은 신촌 external validation 에서 성능이 실제로 좋아지는지로 한다.

즉:

VIF = 경고등

External validation 성능 = 최종 판정

4. Incremental value 의 의미

이 연구에서 가장 중요한 비교는 다음이다.

Model 1: Age + Sex + BMI

Model 2: Age + Sex + BMI + AEC

강남 데이터에서 두 모델을 만들고, 신촌 데이터에 그대로 적용한다.

신촌에서 Model 2 가 Model 1 보다 좋아지면:

AEC 의 incremental value 가 있다.

신촌에서 차이가 없거나 나빠지면:

AEC 는 BMI/protocol/body-size proxy 였을 가능성이 크고, 추가 가치는 약하다.

평가지표는 AUC 만 보면 부족하다. 다음도 같이 봐야 한다.

지표	의미
AUC	환자를 위험순으로 잘 줄 세우는가
AUPRC	low SMI 처럼 양성 비율이 낮은 outcome 에서 유용
Brier score	예측확률의 평균 오차. 낮을수록 좋음
Calibration plot	예측확률과 실제 발생률이 맞는지 보는 그래프

짧게 외우면:

AUC = ranking

Calibration = 확률이 정직한가

Brier = 확률 오차 점수

5. 1D CNN 의 의미

1D CNN 은 결국 AEC curve 를 숫자 배열로 넣는 모델이다.

예를 들어 AEC curve 를 256 point 로 resampling 하면:

[120, 123, 125, 130, ..., 110]

이런 숫자 벡터가 된다.

일반 regression 은 각 숫자를 따로 feature 처럼 보지만, 1D CNN 은 숫자들의 순서와 곡선 모양을 본다.

즉 1D CNN 은 다음을 자동으로 학습할 수 있다.

- 전체 amplitude
- local peak
- plateau
- slope change
- curve asymmetry
- irregularity
- regional pattern

따라서 1D CNN 을 하는 이유는 명확하다.

Handcrafted feature 가 요약하면서 버린 raw AEC morphology 안에 low SMI 정보가 남아 있는지 확인하기 위해서다.

6. 1D CNN 에서 비교해야 할 모델

최소한 다음 모델을 비교해야 한다.

모델	목적
Age + Sex + BMI	clinical baseline
AEC-CNN only	AEC curve 단독 성능
Age + Sex + BMI + AEC-CNN	primary model
Age + Sex + BMI + handcrafted AEC CNN	이 handcrafted 보다 나은지 비교

가장 중요한 primary comparison 은 이것이다.

Age/Sex/BMI vs Age/Sex/BMI + AEC-CNN

이 비교만으로도 1D CNN 의 predictive incremental value 는 판단할 수 있다.

7. CNN 과 clinical variable 의 interaction 문제

누군가 “Age/Sex/BMI 와 CNN 사이 interaction 때문에 설명이 어려울 수 있다”고 말할 수 있다.

그 말이 완전히 틀린 것은 아니다.

AEC curve 의 의미가 BMI 나 sex 에 따라 달라질 수 있기 때문이다.

예를 들어:

- 같은 AEC curve 라도 남자와 여자에서 의미가 다를 수 있음
- 같은 AEC amplitude 라도 BMI 가 높은 사람과 낮은 사람에서 의미가 다를 수 있음

그래서 모델은 두 가지로 나누면 된다.

Primary model: 설명 가능한 방식

먼저 AEC curve 만으로 CNN risk score 하나를 만든다.
그다음 logistic regression 에 넣는다.

Low SMI $\sim$ Age + Sex + BMI + CNN_score

이 방식은 해석이 쉽다.

Secondary model: 성능 중심 방식

AEC curve 와 age/sex/BMI 를 같이 넣는 late-fusion CNN 을 만든다.

AEC curve $\rightarrow$ CNN feature

CNN feature + Age/Sex/BMI $\rightarrow$ final prediction

이 방식은 interaction 을 어느 정도 허용할 수 있지만, 설명가능성은 낮다.

따라서 추천 구조는:

Primary: Age/Sex/BMI + CNN score

Secondary: Late-fusion CNN

8. Scan coverage issue

workflow 상 L3 위치는 input 으로 쓸 수 없다.

따라서 L3-anchored alignment 는 primary model 에 쓰면 안 된다.

주모델은 다음처럼 해야 한다.

Full AEC curve 를 0-100% relative acquisition axis 로 resampling

하지만 scan coverage 가 사람마다 다르면 CNN 이 low SMI 가 아니라 scan range/protocol 차이를 배울 수 있다.

이 문제를 줄이는 방법은 다음과 같다.

~~가장 중요: cohort restriction~~

~~가능하면 primary cohort 는 다음으로 제한한다.~~

~~Routine abdominopelvic CT, portal venous phase, abdomen+pelvis coverage 가
일정한 검사~~

~~제외하거나 별도 분석해야 할 것:~~

- ~~chest=abdomen=pelvis CT~~
- ~~liver dynamic CT~~
- ~~pancreas protocol CT~~
- ~~urogram~~
- ~~pelvis-only CT~~
- ~~limited abdomen CT~~
- ~~scan length 가 너무 짧거나 긴 case~~
- ~~fixed tube current case~~

Coverage 관련 변수 기록

각 case 마다 다음을 저장한다.

- ~~scan length~~
- ~~number of slices~~
- ~~z-axis range~~
- ~~protocol name~~
- ~~scanner model~~
- ~~kVp~~
- ~~CTDIvol~~
- ~~DLP~~
- ~~contrast phase~~

Sensitivity analysis

다음 분석을 추가로 한다.

- full curve 0-100%
- central 80% crop
- central 60% crop
- raw AEC curve
- within-curve normalized AEC curve
- scan length extreme case 제외

결과가 central crop 이나 normalization 에서도 유지되면, scan coverage artifact 가능성이 낮아진다.

9. 1D CNN 결과에 대한 현재 예상

현재 handcrafted 결과만 보면, 1D CNN 이 엄청난 성능 향상을 보일 가능성은 높지 않다.

현실적인 기대는 다음 정도다.

모델	예상
Age/Sex/BMI	AUC 약 0.75
Age/Sex/BMI + handcrafted AEC	거의 0.75
AEC-CNN only	0.68-0.76 가능
Age/Sex/BMI + AEC-CNN	0.76-0.78 정도면 현실적
0.80 근처	꽤 좋은 결과
$\Delta AUC \geq 0.04-0.05$	강한 결과

판정 기준은 대략 이렇게 볼 수 있다.

ΔAUC in 신촌 validation	해석
0.00-0.01	실패 또는 의미 약함
0.02-0.03	논문화 가능성 있음
0.04-0.05	좋은 결과
≥ 0.06	매우 강함. 단, coverage/protocol artifact 확인 필요

10. 요약

1. Outcome 을 정리한다.

가능하면 TAMA 보다 $SMI = TAMA / height^2$ 를 사용한다.
height 가 없으면 low TAMA 라고 명확히 표현한다.

2. 강남 train, 신촌 external validation 구조를 고정한다.

신촌 데이터는 feature selection, hyperparameter tuning, threshold selection 에 쓰지 않는다.

3. AEC curve 를 fixed length 로 만든다.

예: full AEC curve 를 256 point 로 resampling.

4. 최소 모델 4 개를 만든다.

- Age + Sex + BMI
- AEC-CNN only
- Age + Sex + BMI + AEC-CNN
- Age + Sex + BMI + handcrafted AEC

5. Primary comparison 은 이것이다.

Age/Sex/BMI vs Age/Sex/BMI + AEC-CNN

6. 신촌 validation 에서 평가한다.

- AUC
- AUPRC
- Brier score
- calibration plot
- calibration slope/intercept

7. Scan coverage sensitivity 를 한다.

- ~~routine APCT 만 제한~~
- central crop 분석
- ~~within-curve normalization 분석~~
- ~~scan length/protocol/scanner 변수 확인~~

최종 결론

현재까지의 결론은 다음과 같다.

Handcrafted AEC feature 는 TAMA 와 관련이 있지만, BMI 를 넣으면 추가 효과가 거의 사라진다. 따라서 handcrafted feature 분석은 거의 충분히 했고, 이제는 raw AEC curve 기반 1D CNN 으로 넘어가야 한다.

단, 1D CNN 의 의미는 반드시 다음 비교로 판단해야 한다.

강남에서 학습한 Age/Sex/BMI + AEC-CNN 모델이 신촌 external validation 에서 Age/Sex/BMI 모델보다 좋아지는가?

이게 좋아지면 AEC curve 에 BMI 를 넣어서는 정보가 있다고 볼 수 있다.
좋아지지 않으면 AEC 는 주로 body size/BMI proxy 였다고 해석하는 것이 맞다.