

Multimodal Architecture

Clinic + AEC 융합 모델 발표 대본

2026. 06. 26 | JangHoon Chun

Dept. of Medical Device Engineering & Management

Gangnam Severance Hospital, Yonsei University College of Medicine

사용 안내

본 문서는 발표 슬라이드의 슬라이드 노트를 PDF로 정리한 발표 대본입니다.
각 슬라이드 섹션에는 **핵심 설명**과 **예상 Q&A**가 포함되어 있습니다.
발표 전 인쇄하여 참고하거나, 화면에서 열어 QnA 대비 자료로 활용하세요.

목 차

Slide 01 타이틀 – Multimodal (Clinic + AEC) Architecture

Slide 02 목 차

Slide 03 Cross-Attention 개요

Slide 04 Cross-Attention 아키텍처 다이어그램

Slide 05 Late Fusion 개요

Slide 06 Late Fusion 아키텍처 다이어그램

Slide 07 Gated AEC Fusion 개요

Slide 08 Gated AEC Fusion 아키텍처 다이어그램

Slide 09	Meaning-Aware Contrastive AEC 개요
Slide 10	Meaning-Aware Contrastive AEC 전체 플로우
Slide 11	전체 알고리즘 상세 플로우
Slide 12	Model 1 & Model 2 상세
Slide 13	Contrastive Score & AEC 서명 공간
Slide 14	Model 3A / 3B & 최종 판정 규칙
Slide 15	교차검증 구조 & 외부 검증 잠금
Slide 16	마무리

안녕하세요. 저는 연세대학교 의과대학 강남세브란스병원 의료기기공학과 JangHoon Chun입니다. 오늘은 근감소증 저SMI(Low Skeletal Muscle Index) 분류를 위한 Multimodal 아키텍처 탐색 과정과 최종 채택 방법론을 공유드리겠습니다.

본 연구는 CT에서 자동 추출되는 AEC(Automatic Exposure Control) 곡선과 임상 데이터(나이·성별·키·몸무게)를 융합하여 SMI 예측 성능을 높이는 것이 목표입니다. 오늘 발표에서는 탐색한 4가지 아키텍처 – Cross-Attention, Late Fusion, Gated AEC Fusion, 그리고 최종 채택된 Meaning-Aware Contrastive AEC – 를 순서대로 설명드리겠습니다.

예상 질문 Q&A

Q. AEC 곡선이란 무엇인가요?

A. AEC(Automatic Exposure Control)는 CT 촬영 시 X선 관전류를 자동으로 조절하는 값으로, 128개 슬라이스 위치별로 기록되는 1차원 시계열 데이터입니다. 신체 부위별 방사선 투과도를 반영하므로 간접적으로 체성분 분포 정보를 담고 있습니다.

Q. 왜 AEC를 사용하나요?

A. 기존 CT 데이터에서 별도 비용 없이 추출 가능하고, TotalSegmentator 없이도 얻을 수 있어 임상 현장 적용이 용이합니다. 다만 직접적인 근육 면적 측정값이 아니므로, 임상 지표와 융합하는 Multimodal 접근이 필요합니다.

Q. Low SMI(근감소증) 기준은 어떻게 정의하나요?

A. $SMI(Skeletal\ Muscle\ Index) = L3\ 레벨\ 근육\ 면적(cm^2) / 키^2(m^2)$. 성별·인종별 cut-off 기준을 적용해 LowSMI(1) vs Normal(0)으로 이진 분류합니다.

오늘 발표는 총 4개 아키텍처를 순서대로 다룹니다.

1. Cross-Attention: 임상 피처와 AEC 토큰 간 양방향 어텐션으로 상호작용 학습 (딥러닝 탐색 1)
2. Late Fusion: 두 모달리티를 독립 처리 후 단순 concatenation – 베이스라인 비교군 (딥러닝 탐색 2)
3. Gated AEC Fusion: 학습된 α 게이트로 AEC-임상 기여도를 동적 가중 – 중간 시도 (딥러닝 탐색 3)
4. Meaning-Aware Contrastive AEC: 통계 기반, 임상 유사 이웃 대조 → 최종 채택 방법론

1~3번은 End-to-End 딥러닝 방식으로 탐색했으나 외부 코호트 일반화 한계로 폐기하였고, 4번이 현재 운용 중인 최종 알고리즘입니다.

예상 질문 Q&A

Q. 왜 딥러닝을 버렸나요?

A. 강남 내부 교차검증에서는 성능이 나왔으나 신촌 외부 검증 시 일반화가 불안정했고, 통계적 검증(McNemar 등)에서 개선 유의성을 담보하기 어려웠습니다. 또한 임상 현장에서 해석 가능성이 요구되는 규제 환경을 고려해 통계 기반으로 전환했습니다.

Q. 4개 아키텍처를 모두 실험했나요?

A. 네. Cross-Attention → Late Fusion(비교용) → Gated AEC Fusion → Meaning-Aware Contrastive 순서로 탐색하면서 각 방법의 한계를 확인하고 다음 접근으로 전환했습니다.

Cross-Attention 아키텍처 개요입니다.

핵심 아이디어: 임상 지표와 AEC 시계열이 서로를 '참조(attend)'하며 상호 보완적 표현을 학습합니다.

[임상 처리 – ScalarFeatureTokenizer]

- 나이·성별·키·체중 각각을 독립 Linear(1→d) 레이어로 d차원 토큰으로 변환합니다.
- 각 피처가 별도 임베딩 공간을 가지므로 피처 간 스케일 차이에 무관하게 학습 가능합니다.
- 출력 형태: (B, n_clinic, d_model) – 배치 × 피처수 × 임베딩 차원

[AEC 처리 – ResNet1DEncoder]

- Conv1d stem → ResBlock1D × N (skip connection 포함) → AdaptiveAvgPool1d(32)
- 128점 AEC를 32개 토큰으로 압축: (B, 32, d_model)
- 스킵 연결로 기울기 소실 방지, 다양한 지역 패턴(피크·평탄부·경사도) 추출 가능

[Bidirectional Cross-Attention]

- Q=임상 토큰, KV=AEC 토큰: 임상 피처가 AEC의 어느 위치에 주목할지 학습
- Q=AEC 토큰, KV=임상 토큰: AEC가 임상 정보를 참조해 표현 갱신
- N_CA_LAYERS 회 반복, Pre-LayerNorm으로 학습 안정성 확보

[분류 헤드]

- 두 모달리티 mean-pool → concat → MLP → logit → Sigmoid → P(LowSMI)
- Loss: FocalLossWithLogits (클래스 불균형 대응)

[해석 가능성]

- Attention map: 어느 임상 피처가 AEC의 어느 슬라이스 위치에 주목하는지 시각화 가능

예상 질문 Q&A

Q. Pre-norm이 왜 학습 안정성에 유리한가요?

A. 표준 Post-norm(Attn → LayerNorm) 대비 Pre-norm(LayerNorm → Attn)은 기울기가 잔차 경로를 통해 더 안정적으로 흐릅니다. 특히 레이어가 깊어질수록 학습 초기의 발산 위험이 줄어듭니다.

Q. AdaptiveAvgPool로 32 토큰만 남기는 이유는?

A. 128점 AEC 전체를 토큰화하면 Cross-Attention 연산량($O(n^2)$)이 지나치게 커집니다. 32로 압축해도 저주파 형태 정보가 충분히 보존됩니다.

Q. Bidirectional Cross-Attention이 Self-Attention과 다른 점은?

A. Self-Attention은 같은 모달리티 내에서 Q=K=V로 자기 참조합니다. Cross-Attention은 서로 다른 모달리티에서 Q와 KV를 가져와 두 모달리티 간 정보 교환을 학습합니다.

SLIDE 04 Cross-Attention 아키텍처 다이어그램

Cross-Attention 전체 아키텍처 다이어그램입니다. 왼쪽은 임상, 오른쪽은 AEC 처리 경로입니다.

[입력]

- Clinical: (B, n_clin) – 나이·성별·키·체중
- AEC: (B, 128) – 128점 AEC 시계열

[인코더 단계]

- ScalarFeatureTokenizer: 각 임상 피쳐 → Linear(1→d) + Feature Embedding → (B, n_clin, d_model)
- ResNet1DEncoder: Conv1d stem + ResBlock1D×N + AdaptiveAvgPool1d(32) → (B, 32, d_model)

[Bidirectional Cross-Attention × N_CA_LAYERS (Pre-norm)]

- c_tokens = CrossAttn(Q=clinic_tokens, K=aec_tokens, V=aec_tokens): 임상이 AEC에서 정보 수집
- a_tokens = CrossAttn(Q=aec_tokens, K=clinic_tokens, V=clinic_tokens): AEC가 임상에서 정보 수집
- 매 레이어마다 두 모달리티가 서로를 갱신

[풀링 및 분류]

- c_fused.mean(dim=1) → (B, d_model)
- a_fused.mean(dim=1) → (B, d_model)
- Concat → (B, d_model×2) → MLP Head: Linear(d×2→128) → ReLU → Dropout(0.1) → Linear(128→1) → logit
- Output: Sigmoid(logit) = P(LowSMI)
- Loss: FocalLossWithLogits(gamma, pos_weight) + AdamW + CosineAnnealingLR

[핵심 설계 특징]

1. 양방향 상호작용: Clinic↔AEC 서로 참조 → 임상 피쳐가 AEC 어느 구간에 주목하는지 학습
2. Pre-norm: LayerNorm → Attention 순서로 학습 안정성 향상
3. ScalarTokenizer: 각 피쳐에 독립 Linear + 위치 임베딩으로 피쳐별 특성 보존
4. ResNet1DEncoder: Conv1d stem + skip connection으로 AEC 국소 패턴 추출 후 32 토큰 풀링

예상 질문 Q&A

Q. Focal Loss의 gamma 값은 어떻게 설정하나요?

A. gamma는 교차검증으로 탐색합니다. gamma가 클수록 잘 분류되는 쉬운 샘플의 가중치를 더 강하게 낮추며, 일반적으로 2를 기본값으로 씁니다. pos_weight로 클래스 불균형도 추가 보정합니다.

Q. CosineAnnealingLR의 주기는 어떻게 설정하나요?

A. T_max를 전체 에포크 수로 설정해 한 번의 코사인 감소를 적용하거나, warm restart를 여러 번 적용합니다. 학습 초기에는 큰 LR로 빠르게 수렴하고 이후 낮춰 sharp minima를 피합니다.

Q. d_model은 얼마로 설정했나요?

A. 실험에 따라 다르지만 일반적으로 32~128 사이를 탐색했습니다. 너무 크면 소표본에서 과적합, 너무 작으면 표현력 부족의 트레이드오프가 있습니다.

Late Fusion 아키텍처 개요입니다. Cross-Attention의 비교 대상 베이스라인으로 설계했습니다.

[영상 처리] ScalarFeatureTokenizer – Cross-Attention과 동일 구조 → (B, n_clin, d_model)

[AEC 처리] ResNet1DEncoder – Cross-Attention과 동일 구조 → (B, 32, d_model)

[핵심 차이 – Cross-Attention LAYER 없음]

- 두 표현을 각각 mean-pool한 뒤 바로 concatenation
- $c.mean(dim=1)$ $a.mean(dim=1)$ → (B, d_model×2) → MLP Head → logit
- 두 모달리티가 서로를 전혀 참조하지 않음 (상호작용 부재)

[한계]

- 영상 피처가 AEC의 특정 구간에 주목하는 상호작용 학습 불가
 - AEC 정보가 독립적 특징으로만 기여 → 융합 시너지 없음
 - 해석 가능성 낮음 (단순 concat으로 피처 중요도 구분 어려움)
- 결론: Cross-Attention 대비 성능 열등 → 제거

예상 질문 Q&A

Q. Late Fusion이 빠르고 간단한데, 왜 Cross-Attention을 쓰나요?

A. Late Fusion은 AUC 기준으로 Cross-Attention보다 일관되게 열등했습니다. 두 모달리티 간 상호작용 학습이 없으면 AEC 정보가 독립적인 피처로만 기여해 융합 시너지를 얻지 못합니다.

Q. Early Fusion(입력 단계에서 concat)은 시도하지 않았나요?

A. 영상 피처(4차원 스칼라)와 AEC(128점 시계열)는 성격이 매우 달라 단순 입력 concat은 의미가 없습니다. ScalarTokenizer와 ResNet1DEncoder로 각각 적절한 표현을 만든 뒤 융합하는 것이 합리적입니다.

Late Fusion 전체 다이어그램입니다. Cross-Attention과의 구조 비교에 집중해 주세요.

[공통 인코더 (Cross-Attention과 동일)]

- ScalarFeatureTokenizer $\rightarrow (B, n_{\text{clin}}, d_{\text{model}})$
- ResNet1DEncoder $\rightarrow (B, 32, d_{\text{model}})$

[핵심 차이: ★ Cross-Attention 없음]

- 두 표현이 서로를 전혀 참조하지 않은 채 바로 mean-pool $\rightarrow$ concat
- mean(dim=1) $\rightarrow (B, d_{\text{model}})$ 각각 독립적으로
- Concat $\rightarrow (B, d_{\text{model}} \times 2) \rightarrow \text{MLP} \rightarrow \text{logit}$
- Loss: FocalLossWithLogits (동일 설정)

[Cross-Attention vs Late Fusion 비교표 설명]

- 모달리티 상호작용: CrossAttn=명시적 학습(양방향 Attn) / LateFusion=없음(독립 처리)
- AEC $\rightarrow$ Clinic 영향: CrossAttn=O / LateFusion=X
- Clinic $\rightarrow$ AEC 영향: CrossAttn=O / LateFusion=X
- 파라미터 수: CrossAttn=많음(Attn 레이어 추가) / LateFusion=상대적으로 적음
- 성능: CrossAttn=우수 / LateFusion=열등 $\rightarrow$ 제거

결론: Late Fusion의 단순 concat은 Cross-Attention의 상호작용 학습을 대체 불가 $\rightarrow$ 전량 제거

예상 질문 Q&A

Q. 동일한 인코더를 사용한다면 Late Fusion에서도 AEC 정보가 반영되는 것 아닌가요?

A. 반영은 되지만, 상호작용이 없습니다. Cross-Attention에서는 임상 피처가 "AEC의 어느 슬라이스에서 자신과 관련된 패턴이 있는지"를 학습합니다. Late Fusion에서는 그런 참조가 불가능하고 두 표현이 독립적으로 MLP에 입력됩니다.

Q. 파라미터 수가 적는데 소표본에서 Late Fusion이 오히려 유리할 수 있지 않나요?

A. 이론적으로 가능한 주장이지만 실험 결과 Cross-Attention이 일관되게 우수했습니다. 교차검증으로 적절한 정규화를 적용하면 파라미터 수 증가로 인한 과적합을 충분히 제어할 수 있습니다.

Gated AEC Fusion 아키텍처 개요입니다. Cross-Attention의 복잡도를 줄이면서 해석 가능성을 높이려는 시도입니다.

[영상 처리 – 간소화]

- Linear($n_{\text{clinic}} \rightarrow \text{hidden}$) $\rightarrow$ ReLU $\rightarrow$ clin_vec
- ScalarTokenizer보다 간단한 MLP 단일 임베딩

[AEC 처리 – 이중 풀링 추가]

- stem: Conv1d($1 \rightarrow \text{base_ch}$, $k=7$) + ResBlock1D $\times$ N
- 이중 풀링: AdaptiveAvgPool1d $\rightarrow$ avg (전반적 수준), AdaptiveMaxPool1d $\rightarrow$ max (국소 피크)
- cat([avg, max]) $\rightarrow$ aec_fc $\rightarrow$ aec_vec
- 이점: 전체 형태 정보 + 극값 정보를 동시에 활용

[학습된 게이트 α – 핵심]

- $\alpha = \sigma(\text{Linear}(\text{cat}[\text{aec_vec}, \text{clin_vec}] \rightarrow 8) \rightarrow \text{ReLU} \rightarrow \text{Linear}(8 \rightarrow 1) \rightarrow \text{Sigmoid})$
- $\alpha \in (0,1)$: 두 모달리티의 기여도를 환자별로 동적 결정
- $\alpha \rightarrow 1$: AEC 우세 (AEC가 더 중요한 환자) / $\alpha \rightarrow 0$: Clinic 우세 (임상이 더 중요한 환자)
- 환자별 α 값을 출력해 AEC vs Clinic 기여도 수치 확인 가능

[융합 및 분류]

- fused = $\alpha \cdot \text{aec_proj}(\text{aec_vec}) + (1 - \alpha) \cdot \text{clin_proj}(\text{clin_vec})$
- Linear(proj_dim $\rightarrow$ 32) $\rightarrow$ BatchNorm1d $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ logit
- 훈련: BCEWithLogitsLoss / 추론: $\sigma(\text{logit}) \rightarrow P(\text{LowSMI})$

[폐기 배경]

- E2E 딥러닝 블랙박스: 외부 코호트 일반화 불확실
 - α 스칼라는 모달리티 전체 기여도만 표현 – AEC 내 어느 구간이 중요한지는 모름
 - 통계적 검증(McNemar) 적용 어려움
- $\rightarrow$ 통계 기반 Meaning-Aware Contrastive AEC로 전환

예상 질문 Q&A

Q. α 게이트가 Cross-Attention Attention map보다 해석 가능성이 낮은 이유는?

A. α 는 환자 전체에 대한 단일 스칼라이므로 "AEC 전반 vs 임상 전반" 중 어느 쪽이 우세한지만 알 수 있습니다. Cross-Attention map은 어느 임상 피처가 AEC의 어느 시간 위치에 주목하는지 다차원으로 표현해 더 세밀한 해석이 가능합니다.

Q. BatchNorm을 쓰는 이유는?

A. BatchNorm은 학습 과정에서 내부 공변량 이동을 줄여 더 빠른 수렴과 안정적인 학습을 돕습니다. 소표본에서도 배치 통계로 정규화해 Dropout과 함께 과적합 방지 효과가 있습니다.

Gated AEC Fusion 전체 다이어그램과 Cross-Attention과의 비교표입니다.

[전체 플로우 상세]

1. AEC(B,1,128) → stem Conv1d(1→base_ch, k=7) → ResBlock1D×N → intermediate AEC feature
2. Clinic(B,n_clinic) → Linear(n_clinic→hidden) → ReLU → clin_vec
3. 이중 풀링: AdaptiveAvgPool1d → avg / AdaptiveMaxPool1d → max → cat → aec_fc → aec_vec
4. Gate: $\alpha = \sigma(\text{Linear}(\text{cat}[\text{aec_vec}, \text{clin_vec}] \rightarrow 8) \rightarrow \text{ReLU} \rightarrow \text{Linear}(8 \rightarrow 1) \rightarrow \text{Sigmoid})$
- $\alpha \in (0,1)$: $\alpha \rightarrow 1$ AEC 우세 / $\alpha \rightarrow 0$ Clinic 우세 (환자별 모달리티 기여도 수치 해석)
5. Fusion: $\text{fused} = \alpha \cdot \text{aec_proj}(\text{aec_vec}) + (1 - \alpha) \cdot \text{clin_proj}(\text{clin_vec})$
6. Classifier: $\text{Linear}(\text{proj_dim} \rightarrow 32) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Dropout} \rightarrow \text{logit}$
7. 훈련: BCEWithLogitsLoss / 추론: $\sigma(\text{logit}) \rightarrow P(\text{LowSMI})$

[Cross-Attention vs Gated AEC Fusion 핵심 차이표]

항목 | Cross-Attention | Gated AEC Fusion

AEC 인코딩 | ResNet1D → 시퀀스 토큰(32개) | ResNet1D → 이중 풀링 벡터(1개)

임상 처리 | ScalarFeatureTokenizer | Linear → ReLU

통합 방식 | Bidirectional Cross-Attention | α 게이트(스칼라 1개)

해석 가능성 | 어텐션 가중치(다차원) | α 단일 스칼라

모달리티 교차 | Token 수준 세밀한 교차 | 스칼라 혼합 비율만

[폐기 이유 상세]

- E2E 블랙박스: 신촌 외부 검증 시 α 게이트 패턴이 일반화되지 않음
 - 통계 검증 어려움: α 분포로 개선 유의성을 정량화하기 어려움
 - 해석 한계: α 단일 스칼라는 AEC 어느 위치가 근감소증과 관련있는지 설명 불가
- 통계 기반 Meaning-Aware Contrastive AEC로 전환

예상 질문 Q&A

Q. 이중 풀링(avg+max)이 단순 AvgPool보다 나은 이유는?

A. AvgPool은 곡선의 전반적 수준을 포착하고, MaxPool은 국소 피크(복부 지방 집중 구간 등)를 포착합니다. 두 가지를 연결(cat)하면 전체 형태 + 극값 정보를 동시에 활용할 수 있어 AEC의 다양한 형태 패턴을 더 풍부하게 표현합니다.

Q. Gate 네트워크가 Linear(→8)→ReLU→Linear(→1)처럼 작은 이유는?

A. Gate는 "두 모달리티 중 어느 쪽이 더 신뢰할 만한가"라는 단순한 판단을 위한 것입니다. 복잡한 네트워크를 쓰면 게이트 자체가 과적합될 수 있으므로 최소한의 비선형성(ReLU 1개)만 포함합니다.

Meaning-Aware Contrastive AEC – 최종 채택 알고리즘 개요입니다.

[핵심 철학]

"임상적으로 유사한 환자끼리 AEC 패턴을 비교하면, AEC 차이가 순수한 근육 상태 차이를 반영한다."

→ E2E 딥러닝이 아닌 통계적·해석 가능한 워크플로

[임상 처리]

- Model 1: LogReg(나이·성별·키·체중) → P(LowSMI) + Youden threshold
- 성향점수(Propensity Score) 기반: 동일 성별·스캐너 + logit caliper 이웃 매칭

[AEC 전처리 및 특징 추출]

- 전처리: log1p 변환 + Savitzky-Golay 스무딩(window=9) → 노이즈 제거
- 환자별 robust-z 정규화(IQR 기반): 기기·체격 차이 제거
- AEC 서명 공간: segment/DCT/전역 기술자로 수백 차원 특징 벡터 구성

[Pair-wise 대조 점수]

- 쿼리 환자 ↔ Low SMI 이웃 12명, Normal 이웃 12명의 AEC 특징 차이 계산
- $\text{diff} = x[\text{query}] - x[\text{control}] \rightarrow \text{LogReg 분류기} \rightarrow P(\text{LowSMI})$
- 환자별 여러 이웃에 대한 P(LowSMI)를 mean 집계 → 8차원 Contrastive Block

[최종 판정 전략]

- 회색지대(gray_delta=0.075): |임상점수 - threshold| ≤ margin_gate인 경계선 환자만 AEC 개입
- aec_thr=0.80 이상이면 판정 뒤집기, 나머지는 임상 결과 유지
- 민감도를 희생하지 않으면서 특이도를 올리는 보수적 전략

예상 질문 Q&A

Q. Contrastive 접근이 왜 더 해석 가능한가요?

A. "이 환자의 AEC 패턴이 Low SMI 환자 군과 Normal 군 중 어느 쪽에 더 가까운가"라는 직관적 거리 비교입니다. 딥러닝 임베딩이 아닌 물리적으로 의미 있는 AEC 특징 공간에서 비교하므로 임상 의미가 이해하기 쉽습니다.

Q. 왜 gray-zone 환자에게만 AEC를 개입시키나요?

A. 임상 점수가 threshold에서 멀리 떨어진 환자는 임상 모델이 이미 높은 신뢰도로 판단합니다. 불필요한 AEC 개입은 오히려 정확한 예측을 뒤집을 수 있습니다. 경계선 환자에만 개입해 민감도를 보호하면서 특이도를 올리는 전략입니다.

Q. gray_delta=0.075는 어떻게 결정했나요?

A. 강남 내부 교차검증에서 sweep_thresholds()로 margin_gate 값을 그리드 탐색했습니다.
no_sens_drop 규칙(민감도 하락 금지)을 만족하면서 특이도·정확도가 유의하게 개선되는
최적값입니다.

Meaning-Aware Contrastive AEC 전체 플로우 다이어그램과 딥러닝 아키텍처와의 비교표입니다.

[전체 플로우 요약]

1. INPUT: 나이/성별/키/몸무게 + AEC[1..128] + 기기명 + 촬영단계
2. Model 1(Clinical LogReg): P(LowSMI) + threshold → 모든 환자 기준선 예측 생성
3. Model 2(Ridge×2 잔차): 체격·기기 영향을 회귀로 설명 후 잔차로 정규화된 AEC 표현 생성
- raw($\alpha=8$), pz($\alpha=12$), res_raw, res_pz 4종
4. Contrastive Score(학습 없음): Low 이웃 12명 / Normal 이웃 12명과 AEC 서명 공간에서 거리 비교 → 8-dim 벡터
5. correction_features(): 임상(score/thr/margin) + 임상 공변량(age/sex/h/w) + 8-dim Contrastive → ~17차원
6. Model 3A(Rule-Out): 임상 양성 환자에서 FP 예측 (ElasticNet LogReg)
7. Model 3B(Rule-In): 임상 음성 환자에서 FN 예측 (ElasticNet LogReg)
8. Selective Correction Rule(if-else): gray-zone + Rule-Out ↑ → 양성→음성 / gray-zone + Rule-In ↑ → 음성→양성

[딥러닝 vs Meaning-Aware Contrastive 비교표]

항목 | Cross/Late Fusion | Meaning-Aware Contrastive
 학습 방식 | E2E 딥러닝(PyTorch) | 통계 기반 해석 가능 워크플로
 AEC 역할 | 특징 추출 후 직접 분류 | 임상 보정 신호(경계선만 개입)
 임상 모델 | 딥러닝과 통합 | 독립 기준선(LogReg)
 외부 검증 | 제한적 | 신촌 잠금 적용(완전 분리)
 해석 가능성 | 낮음(블랙박스) | 높음(rule-based 개입)
 통계 검증 | AUC 중심 | McNemar 정확 검정 + Sens/Spec/Acc

[설계 전환 배경]

- E2E 딥러닝: 외부 검증 일반화 한계 확인
- GatedAECFusion(α 게이트): 통계 기반으로 전환 필요성 확인
- 현재: 임상 모델 독립 유지 + AEC는 경계선만 보정 → 해석 가능성 + 통계 검증 + 외부 일반화 우선

예상 질문 Q&A

Q. McNemar 검정을 왜 사용하나요?

A. McNemar 검정은 동일 환자에 대해 두 분류기(임상 단독 vs 임상+AEC)의 불일치 쌍을 검정합니다. 짝을 이룬 이진 분류 비교에서 정확 검정이므로 소표본에서도 유효하며, AUC 비교(DeLong)보다 실제 판정 변화를 직접 검정합니다.

Q. Model 2가 '예측 모델'이 아닌 '정규화 도구'라는 의미는?

A. Ridge 회귀로 체격·기기·촬영단계가 AEC에 미치는 영향을 설명한 뒤, 그 잔차(설명 안 된 부분)를 순수 AEC 형태 정보로 씁니다. 즉 체격 차이를 제거한 AEC만 Contrastive 비교에 사용합니다.

SLIDE 11 전체 알고리즘 상세 플로우

전체 알고리즘 상세 플로우 다이어그램입니다. 각 구성 요소의 입출력을 연결해서 설명드리겠습니다.

[INPUT] 환자 1명: 나이/성별/키/몸무게 + AEC[1..128] + 기기명 + 촬영단계

[Model 1 – Clinical Logistic Regression]

- 입력(4차원): age, sex, height, weight
- StandardScaler → LogReg(C=0.7, class_weight=balanced)
- 출력: P(LowSMI) 스칼라 + Youden threshold
- 역할: 모든 환자에게 적용되는 1차 기준선 예측

[Model 2 – Expected-AEC Ridge]

- 입력: 체격 + 기기명 + 촬영단계(one-hot)
- Imputer → Scaler → Ridge×2(raw $\alpha=8$ / pz $\alpha=12$)
- 출력: 4종 AEC 표현(raw/pz/res_raw/res_pz) – 체격·기기 영향이 제거된 순수 AEC 형태
- 역할: AEC 정규화 도구 (예측 모델이 아님)

[Contrastive Score – 학습 없음]

- 훈련셋에서 임상 유사 이웃 탐색: Low SMI 12명 / Normal 12명
- AEC 서명 공간에서 거리 계산
- score = dist(Normal) - dist(Low): 양수=Low SMI 닮음 / 음수=Normal 닮음
- 출력: 8차원 contrastive 벡터

[correction_features() → ~17차원]

[Clinical Score] [threshold] [margin] [margin] [pred] [age, sex, h, w] + [8-dim Contrastive Block]

[Model 3A – Rule-Out Head]

- 훈련 대상: 임상 양성 환자만 / 라벨: 그 중 실제 정상=1 (FP 탐지)
- ElasticNet LogReg(C=0.4, l1_ratio=0.25)
- 출력: P(FP) – 이 양성 예측이 틀렸을 확률

[Model 3B – Rule-In Head]

- 훈련 대상: 임상 음성 환자만 / 라벨: 그 중 실제 LowSMI=1 (FN 탐지)
- 동일 구조
- 출력: P(FN) – 이 음성 예측이 틀렸을 확률

[Selective Correction Rule – if-else, 학습 없음]

- gray-zone: $|\text{clinical_score} - \text{threshold}| \leq \text{margin_gate}$
- gray-zone AND Clinical=양성 AND RuleOut $\uparrow$ → 정상으로 뒤집기
- gray-zone AND Clinical=음성 AND RuleIn $\uparrow$ → LowSMI로 뒤집기
- 그 외 → 임상 결과 유지

예상 질문 Q&A

Q. correction_features에 임상 변수를 다시 넣는 이유는?

A. Model 3A/3B가 "임상 점수가 얼마나 threshold 근처인지(margin)"와 "기존 임상 예측 방향"을 알아야 보정 판단이 더 정확합니다. Contrastive 8차원만으로는 임상 경계선 정보가 부족하므로 임상 변수를 함께 입력합니다.

Q. Rule-Out과 Rule-In을 별도 모델로 나누는 이유는?

A. 양성 환자에서 FP를 잡는 것(Rule-Out)과 음성 환자에서 FN을 잡는 것(Rule-In)은 데이터 분포와 라벨이 다릅니다. 하나의 모델로 통합하면 두 목표 간 혼선이 생기므로 분리합니다.

SLIDE 12 Model 1 & Model 2 상세

Model 1(임상 로지스틱 회귀)과 Model 2(Expected-AEC Ridge) 상세 설명입니다.

[Model 1 – Clinical Logistic Regression 상세]

입력(4차원): age / sex(0=F,1=M) / height / weight

→ StandardScaler: 훈련 fold 평균·표준편차로 정규화 (테스트에 동일 스케일러 적용)

→ LogisticRegression 설정:

- C=0.7: 적절한 L2 정규화 ($C=1/\lambda$ 이므로 작을수록 강한 정규화)
- class_weight=balanced: LowSMI 환자 수가 적어도 동등 가중치 부여
- max_iter=3000: 수렴 보장

출력: predict_proba → P(LowSMI) 스칼라(0~1)

Youden Threshold: 훈련 fold ROC curve에서 $\text{argmax}(\text{Sensitivity} + \text{Specificity} - 1)$

→ 핵심: 테스트 fold에 threshold를 유출하지 않음 (data leakage 방지)

→ 5-fold 교차검증: 각 fold 훈련셋으로 fit → 훈련 score로 threshold 계산 → 테스트셋 OOF score 누적

→ 전체 강남 환자 OOF score = 최종 임상 점수

[Model 2 – Expected-AEC Ridge Regression 상세]

입력: age, sex, height, weight, BMI + 촬영단계 one-hot + 기기명 one-hot

→ SimpleImputer(결측값 중앙값 대체)

→ StandardScaler(훈련셋 기준 정규화)

→ Ridge($\alpha=8$): 다중 출력 회귀 (입력 → 예상 AEC 128점 곡선)

- raw 버전 $\alpha=8$, patientwise-z 버전 $\alpha=12$ (스케일 차이로 최적 α 다름)

잔차 계산: residual = 실제 AEC - Ridge 예측값

→ 체격·기기·단계 영향이 제거된 순수 곡선 모양 정보

4종 AEC 표현 (모두 훈련셋에서만 fit → 테스트 적용):

- raw: log1p 변환 + Savitzky-Golay 스무딩(window=9)
- pz: raw의 환자별 robust-z 정규화(IQR 기반)
- res_raw: raw - Ridge(raw) 잔차
- res_pz: pz - Ridge(pz) 잔차

→ 4종 모두 anatomy_zone_features() + morph_from_curve() 입력으로 사용

※ Model 2는 '예측 모델'이 아닌 '정규화 도구'

예상 질문 Q&A

Q. Savitzky-Golay 스무딩을 쓰는 이유는?

A. CT AEC 곡선은 호흡 아티팩트 등으로 고주파 노이즈가 있습니다. SG 스무딩은 다항식 적합으로 국소 형태(피크·기울기)를 보존하면서 노이즈를 제거합니다. 단순 이동평균보다 에지 보존이 우수합니다.

Q. robust-z 정규화가 표준 z-score와 다른 점은?

A. 표준 z-score는 평균과 표준편차를 쓰므로 이상치에 민감합니다. robust-z는 중앙값과 IQR을 사용해 이상치의 영향을 최소화합니다. AEC 곡선처럼 극단값이 존재할 수 있는 데이터에 적합합니다.

Q. Ridge α 값은 어떻게 선택했나요?

A. 교차검증으로 잔차의 분산을 최소화하는 α 를 탐색했습니다. raw($\alpha=8$)와 pz($\alpha=12$)가 다른 이유는 정규화 후 스케일이 달라 최적 정규화 강도가 다르기 때문입니다.

Q. BMI를 입력에 추가한 이유는?

A. 체격 관련 변수 중 BMI는 체중/키²로 신체 비만도를 요약하는 복합 지표입니다. AEC에 미치는 비선형적 영향을 포착하기 위해 독립 변수로 추가했습니다.

Contrastive Score 계산 상세와 AEC 서명 공간 구성 요소 설명입니다.

[① 임상 유사 이웃 탐색 – `clinical_match_matrix()`]

- age, sex×8, height, weight, BMI 표준화 후 훈련셋 전원과 유클리드 거리 계산
- sex에 ×8 가중: 이성 이웃 선택 억제 (성별이 다르면 근육 구성이 근본적으로 달라 AEC 비교가 무의미)
- 가장 가까운 Low SMI 12명 / Normal 12명 각각 선택

[② AEC 서명 공간 구성 – 수백 차원]

- `morph_from_curve(pz) + morph_from_curve(res_pz) + anatomy_zone_features(raw,pz,res_raw,res_pz)`
- 이 공간에서 이웃까지 거리 계산 (훈련셋 기준으로 표준화)

[③ 대조 점수 계산]

- `dist_to_low[12], dist_to_normal[12]` 계산
- 가중치: $\exp(\text{임상거리}) \rightarrow$ 임상적으로 유사할수록 높은 가중치
- `score = mean(dist_normal) - mean(dist_low)`
- 양수 $\rightarrow$ Low SMI 닮음 / 음수 $\rightarrow$ Normal 닮음

[출력: 8차원 Contrastive Block (환자 1명당)]

- [0] 핵심 점수: `mean(dist_normal) - mean(dist_low)` — 양수=LowSMI 닮음, 음수=Normal 닮음
- [1] 최근접 점수: `nearest_normal - nearest_low`
- [2] Low 평균거리: `mean_dist_to_low_neighbors`
- [3] Normal 평균거리: `mean_dist_to_normal_neighbors`
- [4] Low 최근접: `nearest_dist_to_low`
- [5] Normal 최근접: `nearest_dist_to_normal`
- [6] Low 이웃 가중비율: `sum(case_w) / (sum(case_w) + sum(ctrl_w))`
- [7] 임상거리 편향: `mean_clin_dist(low) - mean_clin_dist(normal)`

[AEC 서명 공간 구성 요소 상세]

1. `segment_features(x, 2/4/8/16)`: 구간 분할별 `mean·std·min·max·range·slope·|d1|.mean·|d1|.max` $\rightarrow$ 다해상도 형태 요약
 2. `inverse_features_from_x(x)`: 전역 기술자 22종 (3분위·4분위 평균, 중앙 구간, 무게중심, 1·2차 미분 통계)
 3. `dct_features_from_x(x,16)`: DCT 저주파 16계수 + d1 DCT 8계수 $\rightarrow$ 곡선 전체 형태의 주파수 표현
 4. `anatomy_zone_features`: 6구역(상복부1·2, 중복부1·2, 하복부, 골반) $\times$ 4종 곡선 $\times$ 8통계 + 구역간 비율
- ※ `apply_is_train=True` 시 자기 자신을 이웃에서 제외 (OOF 자기참조 방지)
- ※ 이웃 가중치: $\exp(\text{임상거리})$

예상 질문 Q&A

Q. 왜 이웃을 12명으로 했나요?

A. 너무 적으면($k < 5$) 거리 추정 분산이 크고, 너무 많으면 임상적으로 유사하지 않은 환자까지 포함됩니다. $k=12$ 는 강남 코호트 크기에서 충분한 통계적 안정성을 확보하면서 유사 이웃만 선별하는 균형점입니다.

Q. DCT 계수를 쓰는 이유는?

A. DCT는 AEC 곡선의 전체 형태를 주파수 성분으로 분해합니다. 저주파 16계수는 전반적인 형태 트렌드를, d1 DCT는 기울기 변화 패턴을 포착합니다. 원래 128점보다 훨씬 압축된 표현이므로 이웃 탐색이 효율적이고 과적합 위험도 낮습니다.

Q. 6구역 분할이 해부학적으로 어떤 의미인가요?

A. CT 슬라이스를 상복부~골반까지 6개 해부학적 구역으로 나눕니다. 각 구역의 AEC 수준은 해당 부위의 조직 밀도(근육/지방 비율)를 반영하므로, 구역별 AEC 통계가 근감소증 판별에 의미있는 특징이 됩니다.

Q. Contrastive 8차원을 모두 쓰는 이유는?

A. [0]번 핵심 점수 하나만으로는 거리 분포의 다양한 측면을 놓칩니다. 최근접 이웃 거리([1],[4],[5])는 극단적 유사 환자 존재를 포착하고, 가중비율([6])은 임상 유사도를 반영한 AEC 군 귀속을 나타냅니다. 8차원 모두를 SelectKBest로 필터링하면 Model 3A/3B가 필요한 것만 선택합니다.

SLIDE 14 Model 3A / 3B & 최종 판정 규칙

Model 3A(Rule-Out) / 3B(Rule-In) 보정 모델과 최종 판정 규칙 상세 설명입니다.

[correction_features() 입력 구성 - ~17차원]

[Clinical Score] [threshold] [margin=score_thr] [|margin|] [pred=0/1] [age] [sex] [h] [w] + [8-dim Contrastive Block]

→ margin: 경계선에서 얼마나 멀리 떨어져 있는지

→ |margin|: 거리의 절댓값 (gray-zone 여부 표시)

[Model 3A – Rule-Out Head 상세]

- 훈련 대상: 임상 양성(pred=1) 환자만 (False Positive 탐지 목표)
- 라벨 정의: $y = (y_true == 0) \rightarrow$ 실제 정상이면 1 (이 양성 예측은 틀림)
- 해석: $P(rule_out) \uparrow \rightarrow$ "이 양성 예측은 틀렸을 가능성 높음"
- 적용: gray-zone AND pred=1 AND ruleout_score $\geq$ ruleout_thr $\rightarrow$ pred=False

[Model 3B – Rule-In Head 상세]

- 훈련 대상: 임상 음성(pred=0) 환자만 (False Negative 탐지 목표)
- 라벨 정의: $y = (y_true == 1) \rightarrow$ 실제 LowSMI이면 1 (이 음성 예측은 틀림)
- 해석: $P(rule_in) \uparrow \rightarrow$ "이 음성 예측은 틀렸을 가능성 높음"
- 적용: gray-zone AND pred=0 AND rulein_score $\geq$ rulein_thr $\rightarrow$ pred=True

[공통 Pipeline – make_correction_model()]

SimpleImputer(strategy=median) $\rightarrow$ NaN 처리

$\rightarrow$ StandardScaler $\rightarrow$ 훈련 fold 통계로 정규화

$\rightarrow$ SelectKBest(f_classif, k=min(160, n_features)) $\rightarrow$ 통계 유의 피처만 선택

$\rightarrow$ ElasticNet LogReg:

- penalty=elasticnet / l1_ratio=0.25 / C=0.4 / solver=saga / max_iter=8000

- class_weight=balanced / L1+L2 혼합: 불필요 피처 0 제거 + 과적합 방지

[apply_selective() – 최종 판정 규칙]

gray-zone 정의: $|clinical_score - threshold| \leq margin_gate$

Rule-Out 조건: gray-zone AND clinical_pred=True AND ruleout_score $\geq$ ruleout_thr $\rightarrow$ pred=False

Rule-In 조건: gray-zone AND clinical_pred=False AND rulein_score $\geq$ rulein_thr $\rightarrow$ pred=True

나머지: gray-zone 밖 or 보정 조건 미충족 $\rightarrow$ clinical_pred 그대로 유지

※ fit_or_dummy(): 보정 대상 클래스가 1개뿐인 fold $\rightarrow$ DummyClassifier로 대체

※ McNemar 정확 검정으로 개선 유의성 확인

예상 질문 Q&A

Q. l1_ratio=0.25의 의미는?

A. ElasticNet에서 l1_ratio는 L1(Lasso)과 L2(Ridge) 혼합 비율입니다. 0.25이면 25% L1 + 75% L2입니다. L1은 불필요 피처를 0으로 희소화하고, L2는 과적합을 방지합니다. 두 정규화를 혼합해 소표본 고차원 환경에서 안정성을 확보합니다.

Q. SelectKBest k=160은 어떻게 결정했나요?

A. AEC 서명 공간이 수백 차원이라 전체 사용 시 $n_samples < n_features$ 문제가 생깁니다. k=160은 ANOVA F값 상위 피처를 충분히 포함하면서 과적합을 방지하는 실험적 값입니다.

Q. DummyClassifier로 대체하는 경우는 언제인가요?

A. 특정 fold에서 임상 양성 환자 중 실제 정상인이 0명이면 Rule-Out 모델을 학습할 수 없습니다. DummyClassifier(가장 빈번한 클래스 예측)로 대체해 파이프라인이 중단되지 않도록 합니다.

Q. McNemar 검정의 귀무가설은 무엇인가요?

A. "두 분류기(임상 단독 vs 임상+AEC)의 오류율이 동일하다"입니다. 불일치 쌍(한 쪽만 맞춘 케이스)의 비대칭성을 카이제곱으로 검정합니다. $p < 0.05$ 이면 개선이 유의합니다.

강남 내부 중첩 교차검증 구조와 신촌 외부 검증의 잠금 적용 전략 상세 설명입니다.

[강남 내부 – 중첩 교차검증 구조 (Nested CV)]

외부 5-fold (StratifiedKFold, SEED=20260622):

- 외부 훈련셋(80%) / 외부 테스트셋(20%)
- 계층 분할로 LowSMI 비율 유지

내부 4-fold (inner_clinical_predictions_for_training):

- 목적: 보정 모델(3A/3B) 훈련 라벨을 만들기 위한 임상 OOF 점수
- 외부 훈련셋 내에서 임상 점수를 out-of-fold 방식으로 생성
- 같은 환자의 in-sample 예측을 라벨로 쓰지 않음 → label leakage 방지

[강남 내부 각 fold 처리]

- ① 내부 4-fold로 외부 훈련셋의 임상 OOF 점수 생성
 - ② 보정 모델 3A/3B 훈련 (내부 OOF 임상점수로 라벨 생성)
 - ③ 외부 테스트셋에 RuleOut/RuleIn Score 예측
 - ④ Selective Correction 적용 → 최종 예측
 - ⑤ 성능 집계 후 OOF 전체 누적
- 5개 fold 반복 → 전체 강남 환자 OOF 점수 완성 (internal CV 결과)

[신촌 외부 검증 – 잠금 적용]

1. 강남 전체로 임상 모델 훈련: 모든 강남 환자로 fit → Youden threshold 계산
2. Contrastive Block 계산: 강남 서명 공간 기준으로 신촌 대조 점수 계산
3. 보정 모델 훈련: 강남 OOF 임상점수(5-fold)로 라벨 생성 → 3A/3B fit → 신촌에 RuleOut/RuleIn 예측
4. 잠금 threshold 적용: 강남 내부 CV에서 선택한 ro_thr/ri_thr/margin_gate → 신촌 결과를 보고 절대 수정하지 않음

[threshold 선택 기준 – sweep_thresholds()]

ro_grid × ri_grid × margin_gate 수천 조합 탐색

no_sens_drop 규칙 (세 조건 모두 충족해야 함):

- SpecificityDiff > 0 AND Specificity_p < 0.05 (특이도 유의 개선)
- AccuracyDiff > 0 AND Accuracy_p < 0.05 (정확도 유의 개선)
- SensitivityDiff >= 0 (민감도 하락 금지 – 엄격한 조건)

→ 위 조건 만족 중 NetCorrected 최대인 조합 선택

※ McNemar 정확 검정 사용 (소표본에서도 유효)

예상 질문 Q&A

Q. 왜 중첩 교차검증이 필요한가요?

A. 단순 5-fold에서 임상 점수로 보정 모델을 훈련하면 같은 환자의 in-sample 예측이 라벨로 쓰여 낙관적 편향(optimistic bias)이 생깁니다. 내부 4-fold로 OOF 임상 점수를 만들면 보정 모델도 진정한 out-of-fold 평가가 됩니다.

Q. no_sens_drop 규칙이 민감도 하락을 금지하는 이유는?

A. 근감소증 선별에서 FN(실제 LowSMI를 Normal로 예측)은 치료 기회 상실로 이어집니다. 민감도를 희생하지 않으면서 특이도·정확도가 유의하게 개선되는 threshold만 선택해 임상 안전성을 확보합니다.

Q. 신촌 threshold를 절대 수정하지 않는 이유는?

A. threshold를 신촌 결과를 보고 조정하면 외부 검증이 사실상 학습 데이터가 됩니다. 강남 CV에서 결정한 threshold를 신촌에 그대로 적용해야 진정한 독립 외부 검증이 됩니다. FDA/CE 규제 요건에서도 외부 검증 데이터는 모델 선택에 관여하면 안 됩니다.

Q. SEED=20260622인 이유는?

A. 재현성을 위한 고정 랜덤 시드입니다. 날짜 기반으로 설정해 언제 실험했는지 추적할 수 있고, 임의로 선택했을 때 결과가 달라지는 seed hacking을 방지합니다.

발표 마무리입니다. 오늘 내용을 정리하겠습니다.

[탐색 여정 요약]

1. Cross-Attention: 임상↔AEC 양방향 토큰 수준 상호작용. 성능 우수하나 E2E 딥러닝 외부 일반화 한계로 폐기.
2. Late Fusion: Cross-Attention과 동일 인코더에서 상호작용만 제거한 베이스라인. 상호작용 부재로 열등 → 제거.
3. Gated AEC Fusion: α 스칼라 게이트로 모달리티 기여도 동적 가중. 해석 가능하지만 블랙박스 한계 → 폐기.
4. Meaning-Aware Contrastive AEC (현재 운용): 통계 기반, 임상 유사 이웃 대조, gray-zone 선택적 보정.

[현재 알고리즘의 강점]

- 해석 가능성: rule-based 개입으로 임상이가 판정 근거를 이해 가능
- 통계 검증: McNemar 정확 검정으로 개선 유의성 담보
- 외부 일반화: 신촌 완전 잠금 적용으로 진정한 독립 검증
- 민감도 보호: no_sens_drop 규칙으로 FN 증가 방지
- 독립 임상 모델: AEC 실패해도 임상 모델 단독으로 동작

[향후 방향]

- 신촌 외부 검증 결과 공유 및 McNemar 검정 유의성 확인
- AEC 서명 공간 피쳐 중요도 분석 (SelectKBest 선택 피쳐 해석)
- 임상 적용을 위한 규제 대응 전략 수립

예상 질문 Q&A

Q. 향후 딥러닝으로 돌아갈 가능성이 있나요?

A. 데이터가 충분히 확보되고 외부 코호트 다양성이 보장된다면 재탐색 가능합니다. 현재는 통계 기반이 규제 승인 경로와 임상 해석 가능성 측면에서 더 실용적인 선택입니다. 데이터 규모 10배 이상 확보 시 딥러닝 재고려가 적절합니다.

Q. 이 연구의 임상적 기여는 무엇인가요?

A. 기존 CT 장비에서 별도 소프트웨어 없이 자동 수집되는 AEC 데이터를 활용해 근감소증 선별 정확도를 높입니다. 경계선 환자에 대한 AEC 보정으로 불필요한 추가 검사(TotalSegmentator 기반 근육 면적 측정)를 줄이고 임상 워크플로를 개선할 수 있습니다.