

AEC Virtual Phenotype 분석 지시서

Stage 1 AEC-derived virtual body-composition phenotype → Stage 2 low SMI prediction

핵심 문장: AEC 는 low SMI 를 직접 맞히는 변수가 아니라, scanner 가 인식한 virtual body habitus 를 제공한다. 이 virtual phenotype 과 실제 체중/키 기반 체형 사이의 discordance 가 low SMI 예측에 추가 정보를 주는지 평가한다.

0. 이번 분석의 핵심 목표

- 기존 방식처럼 AEC feature 를 low SMI binary outcome 에 직접 넣지 않는다.
- AEC curve 로부터 scanner-derived virtual body-composition phenotype 을 먼저 복원한다.
- 이 virtual phenotype 이 Age, Sex, Weight, Height 이후에도 low SMI prediction 에 incremental value 를 주는지 평가한다.
- 최종 주장은 “AEC 가 직접 low SMI 를 진단한다”가 아니라 “AEC-derived virtual body habitus / anthropometric discordance 가 추가 정보를 제공한다”로 잡는다.

AEC curve

- scanner-perceived virtual body-composition phenotype
- clinical variables + virtual phenotype
- low SMI prediction

1. 데이터 구성

1-1. 사용할 sheet

Sheet	사용 변수	역할
metadata	PatientID, Age, Sex, Weight, Height, BMI, TAMA, IMATA, SMI, kVp, mAs, scanner model	clinical 변수, outcome, acquisition metadata
aec_128	PatientID, n_slices, z_range, aec_1~aec_128	AEC curve input 및 scan coverage 변수

1-2. 기본 전처리

- PatientID 기준으로 metadata 와 aec_128 을 merge 한다.
- 중복 PatientID 는 제거한다.
- Age, Sex, Weight, Height, BMI, TAMA, IMATA, SMI, kVp, mAs, AEC 값 결측이 있으면 제외한다.
- 18 세 미만은 제외한다.
- Fixed tube current case 가 제외되어 있는지 재확인한다.
- Height 단위가 cm 인지 m 인지 반드시 확인한다.

2. Outcome 정의

2-1. Primary outcome: Yoon low SMI

NAMA = TAMA - IMATA

Height_m = Height_cm / 100

SMI = NAMA / Height_m²

Yoon low SMI cutoff:

Male: SMI < 40.96

Female: SMI < 30.60

- SMI 가 이미 파일에 있어도, NAMA 와 Height 를 이용해 다시 계산해서 consistency 를 확인한다.
- Yoon low SMI 를 primary binary outcome 으로 사용한다.

2-2. Secondary outcome

- sex-specific low SMI Q25 를 sensitivity/exploratory outcome 으로 사용한다.
- 남자와 여자 각각에서 SMI 하위 25%를 low 로 정의한다.

3. AEC feature 생성

3-1. AEC 128-point curve

- aec_1~aec_128 을 하나의 1D curve 로 사용한다.
- Column-wise standard scaling 은 사용하지 않는다.
- Primary 는 raw 또는 train-set 기준 global scaling 으로 한다.
- Row-wise normalization 은 shape-only sensitivity 로만 사용한다.

3-2. 8 등분 segment feature

```
s1 = aec_1 ~ aec_16
s2 = aec_17 ~ aec_32
s3 = aec_33 ~ aec_48
s4 = aec_49 ~ aec_64
s5 = aec_65 ~ aec_80
s6 = aec_81 ~ aec_96
s7 = aec_97 ~ aec_112
s8 = aec_113 ~ aec_128
```

- 각 segment 에서 아래 feature 를 생성한다.

```
s1_mean ~ s8_mean
s1_std ~ s8_std
s1_auc ~ s8_auc
s1_slope ~ s8_slope
```

3-3. Global / relation / DCT feature

Feature group	Feature list
Global AEC	aec_mean, aec_std, aec_cv, aec_auc, aec_min, aec_max, aec_range, aec_skewness, aec_kurtosis
Segment relation	upper_half_mean, lower_half_mean, upper/lower ratio, lower/upper ratio, s1/s8, s2/s7, s3/s6, s4/s5, mirror differences, center_of_mass
DCT low-frequency	dct_1 ~ dct_8
Acquisition	kVp, mAs, z_range, n_slices, scanner model one-hot

4. 분석 구조: Two-stage model

4-1. Stage 1: AEC-derived virtual phenotype model

- 목적: AEC curve 와 acquisition feature 만 보고 continuous body-composition phenotype 을 예측한다.

구분	내용
Stage 1 input	AEC 8-segment features, AEC global features, DCT features, kVp, mAs, z_range, n_slices, scanner model
Stage 1 target	TAMA, NAMA, IMATA, SMI, Weight, Height, BMI
Model 후보	Primary: Random Forest Regressor 또는 XGBoost Regressor; baseline: Ridge Regression
보고 지표	Pearson r, R ² , RMSE, MAE, scatter plot

- Weight, Height, BMI 는 Stage 2 에 raw predicted value 로 넣기 위한 것이 아니다.
- 이들은 AEC-perceived body habitus 와 anthropometric discordance 를 만들기 위한 auxiliary target 이다.

- Stage 1 prediction 은 반드시 out-of-fold prediction 이어야 한다.

5. Cross-fitting 원칙

5-1. 금지 방식

전체 데이터로 Stage 1 model 학습

→ 같은 데이터에서 predicted phenotype 생성

→ Stage 2 학습

- 위 방식은 data leakage 이며 논문용 결과로 사용할 수 없다.

5-2. 반드시 사용할 방식

Outer 5-fold CV:

1. outer train / outer validation 을 나눈다.
2. outer train 내부에서 inner CV 를 수행한다.
3. inner CV 로 outer train 환자들의 Stage 1 OOF predicted phenotype 을 만든다.
4. outer train 전체로 Stage 1 model 을 다시 학습한다.
5. 이 Stage 1 model 로 outer validation 환자들의 predicted phenotype 을 만든다.
6. outer train 의 OOF predicted phenotype 으로 Stage 2 model 을 학습한다.
7. outer validation 의 predicted phenotype 으로 Stage 2 prediction 을 수행한다.
8. 모든 outer validation prediction 을 모아서 최종 OOF performance 를 계산한다.

- 핵심: Stage 2 가 보는 predicted phenotype 은 항상 out-of-fold prediction 이어야 한다.

6. Stage 2: low SMI prediction model

6-1. Primary baseline

Model 1:

Low SMI ~ Age + Sex + Weight + Height

- BMI 대신 Weight 와 Height 를 사용한다.
- BMI 는 Weight/Height²의 요약값이므로, Weight 와 Height 를 분리하면 실제 체격 정보를 더 투명하게 보정할 수 있다.
- SMI 도 Height²가 들어가는 index 이므로 Height 를 명시적으로 포함하는 것이 자연스럽다.

6-2. AEC-added model

Model 2:

Low SMI ~ Age + Sex + Weight + Height

+ AEC-derived virtual body-composition phenotype

+ AEC-perceived anthropometric discordance

6-3. Stage 2 에 넣을 AEC-derived 변수

변수군	변수
Virtual muscle phenotype	AEC_predicted_TAMA, AEC_predicted_NAMA, AEC_predicted_IMATA, AEC_predicted_SMI
AEC-perceived discordance	AEC_BMI_discordance, AEC_Weight_discordance, AEC_Height_discordance
Optional index	AEC_predicted_NAMA_index = AEC_predicted_NAMA / actual_Height ²

AEC_BMI_discordance = AEC_predicted_BMI - actual_BMI

AEC_Weight_discordance = AEC_predicted_Weight - actual_Weight

AEC_Height_discordance = AEC_predicted_Height - actual_Height

- predicted BMI/Weight/Height 를 raw variable 처럼 설명하지 않는다.
- 반드시 scanner 가 인식한 가상 체형과 실제 체형 사이의 불일치, 즉 AEC-perceived anthropometric discordance 로 해석한다.

- actual TAMA/NAMA/IMATA/SMI 는 Stage 2 input 에 절대 넣지 않는다.

7. 최종 비교 모델

분석	비교
Primary comparison	Age + Sex + Weight + Height vs Age + Sex + Weight + Height + AEC-derived virtual phenotype + discordance
Sensitivity 1	Age + Sex + BMI + Height vs Age + Sex + BMI + Height + AEC-derived virtual phenotype + discordance
Sensitivity 2	Age + Sex + Weight + Height + actual BMI vs same + AEC-derived virtual phenotype + discordance
Negative control	Age + Sex + Weight + Height + shuffled AEC-derived virtual phenotype

- Negative control 에서 shuffled AEC model 이 baseline 수준으로 떨어져야 한다.
- 이 결과가 있어야 feature 수 증가 때문이 아니라 환자별 AEC 정보 때문이라고 주장할 수 있다.

8. 평가 지표 및 통계

- 각 모델에 대해 AUC, AUPRC, Brier score, calibration intercept, calibration slope, calibration plot 을 보고한다.
- Model 1 과 Model 2 는 paired prediction 이므로 paired bootstrap 으로 비교한다.
- Bootstrap 은 2,000 회 이상 권장한다.

각 bootstrap sample 에서 계산:

$$\Delta AUC = AUC(\text{Model 2}) - AUC(\text{Model 1})$$

$$\Delta AUPRC = AUPRC(\text{Model 2}) - AUPRC(\text{Model 1})$$

$$\Delta \text{Brier} = \text{Brier}(\text{Model 2}) - \text{Brier}(\text{Model 1})$$

보고:

Δ , 95% CI, p-value

- Brier 는 낮을수록 좋으므로 ΔBrier 가 negative 이면 improvement 로 해석한다.

9. 현재 강남 internal result 기준 benchmark

Outcome	Model	AUC	AUPRC	Brier
Yoon low SMI	Age + Sex + Weight + Height	0.807	0.391	0.0790
Yoon low SMI	+ AEC-derived virtual phenotype	0.826	0.418	0.0770

Metric	Incremental value
ΔAUC	+0.019
95% CI	약 +0.001 to +0.037
p-value	약 0.039

- 학생은 위 결과를 재현하는 것을 1 차 목표로 한다.
- AUPRC 와 Brier 는 방향성은 좋으나 $p < 0.05$ 가 아닐 수 있다. 현재 main claim 은 AUC improvement 이다.

10. 결과 해석 문장

10-1. 영어 표현

- AEC curve directly classified low SMI poorly.
- However, AEC-derived virtual body-composition phenotype improved low SMI prediction beyond age, sex, weight, and height.
- The key information was not predicted anthropometry itself, but the discordance between actual anthropometry and AEC-perceived body habitus.
- This suggests that AEC curves encode body-shape and attenuation information not fully captured by conventional clinical variables.

10-2. 한국어 표현

- AEC curve 자체를 low SMI binary classifier 로 바로 쓰면 성능 향상은 제한적이었다.
- 그러나 AEC curve 로부터 복원한 virtual body-composition phenotype 을 사용하면, 나이·성별·체중·키를 보정한 뒤에도 low SMI 예측력이 향상되었다.
- 특히 실제 체격과 AEC 가 인식한 가상 체격 사이의 불일치가 추가 정보를 제공한 것으로 해석된다.
- 이는 AEC curve 가 단순 선량 정보가 아니라, BMI/체중/키로 설명되지 않는 체형 및 감쇠 profile 을 담고 있음을 시사한다.

11. 발표 슬라이드 구성

Slide	내용
1. Research question	Can scanner-derived AEC curves encode latent body-composition information beyond clinical anthropometry?
2. 기존 접근의 한계	AEC handcrafted feature 를 low SMI 에 직접 넣으면 Age/Sex/BMI 를 뚜렷하게 넘지 못함.
3. 새로운 접근	Stage 1: AEC curve → virtual body-composition phenotype. Stage 2: clinical variables + virtual phenotype → low SMI.
4. Stage 1 성능	TAMA, NAMA, SMI scatter plot 및 Pearson r 제시.
5. Stage 2 main result	ROC curve 와 AUC table. 0.807 → 0.826, $p \approx 0.039$.
6. Calibration / Brier	Calibration plot 과 Brier 방향성 제시.
7. Negative control	True AEC vs shuffled AEC 결과 비교.
8. Interpretation	AEC 는 scanner-perceived body habitus 를 제공하는 acquisition biomarker.

12. 금지사항

- actual TAMA, actual NAMA, actual IMATA, actual SMI 를 Stage 2 input 에 넣지 말 것.
- 전체 데이터로 Stage 1 을 학습한 뒤 같은 데이터의 prediction 을 Stage 2 에 쓰지 말 것.
- 신촌 데이터를 feature selection, threshold selection, hyperparameter tuning 에 쓰지 말 것.
- p-value 를 좋게 만들기 위해 outcome 이나 feature set 을 계속 바꾸지 말 것.
- predicted BMI/Weight/Height 를 raw variable 처럼 설명하지 말 것.
- 반드시 AEC-perceived anthropometric discordance 로 해석할 것.
- Column-wise scaling 은 사용하지 말 것.
- Cross-attention/gating/128×128 matrix 는 이번 분석에서 제외할 것.

13. 다음 액션 아이템

13-1. 이번 주까지

- 위 pipeline 을 코드로 정리한다.
- Stage 1 cross-fitting 을 구현한다.
- Yoon low SMI primary result 를 재현한다.
- Bootstrap CI/p-value 를 계산한다.
- Calibration plot 을 생성한다.
- Shuffled AEC negative control 을 추가한다.

13-2. 다음 미팅 발표자료

- 분석 workflow diagram 1 장
- Stage 1 prediction scatter plot 3 장: TAMA, NAMA, SMI
- Stage 2 ROC curve 1 장
- AUC/AUPRC/Brier table 1 장

- Bootstrap Δ AUC CI table 1 장
- Negative control 결과 1 장
- Limitation 1 장